

Алгоритми перетворення інформації.
Завдання 1, звіт

Михайло Голуб

27 лютого 2025 р.

Реалізація функції `encode(in_bytes)` для RLE:

На вхід приймається масив байтів `in_bytes`. Створюються пусті масиви байтів `output` та `bufer`.

Для кожного байту з вхідного масиву:

1. Перевірка на переповнення буфера:

Якщо довжина буфера більша за 127 і буфер містить різні символи – додати службовий байт "переписати 128 символів" до вихідного масиву (дялі – VM), переписати буфер до VM та очистити буфер;

Якщо довжина буфера рівна 129 і буфер містить однакові символи – додати службовий байт "повторення 129 разів" і перший байт з буфера до Вихідного масиву та очистити буфер.

2. Перевірка на закінчення послідовності різних байтів:

Якщо довжина буфера більша за 1 і поточний обраний байт рівний останньому байту буфера, але не рівний передостанньому – завершено послідовність різних байтів. До VM додається службовий байт виду 0*****, де значення молодших бітів плюс 1 – кількість байтів які треба переписати декодеру після даного службового байту. Після службового байту, до VM додається буфер, після чого буфер очищується.

3. Перевірка на закінчення послідовності однакових байтів:

Якщо довжина буфера більша за 1 і поточний обраний байт не рівний останньому байту буфера і останній та передостанній байти буфера рівні – завершено послідовність однакових байтів. До VM додається службовий байт виду 1*****, де значення молодших бітів плюс 2 – кількість повторень наступного байту які має зробити декодер. Після службового байту, до VM додається перший байт з буфера, після чого буфер очищується.

4. Додати поточний байт до буфера

Після завершення циклу, якщо буфер не порожній, виконуються кроки аналогічні крокам 2 та 3.

Функція повертає сформований вихідний масив байтів `output`

Реалізація функції `decode(in_bytes)` для RLE:

На вхід приймається масив байтів `in_bytes`. Створюється пустий масив байтів `output` та змінна `pointer`. Доки значення `pointer` менше за довжину вхідного масиву:

1. Якщо байт на позиції `pointer` у вхідному масиві більший за 127 – записати у ВМ `байт-126` разів байт на позиції `pointer+1`. Збільшити `pointer` на 2.
2. Інакше – переписати наступні `байт+1` байтів у ВМ. Збільшити `pointer` на `байт+2`.

Функція повертає сформований вихідний масив байтів.

Взаємодія з реалізованими функціями RLE:

Функції `encode` та `decode` знаходяться у файлах `rle_encode.py` та `rle_decode.py`. При запуску файлу з бажаною функцією як головного файлу (відкрити за допомогою інтерпритатора) у консоль виводяться короткі підказки та користувач може ввести бажані шляхи до початкового файлу та кінцевого результату.

Також створено програму `rle_main.py` яка приймає на вхід команди виду `encode;source;destination` та `decode;source;destination` усі символи (у т.ч. пробіли) після ; будуть вважатись частиною шляху.

Приклади правильного використання команд:

```
encode;file.txt; – вихідний файл буде мати шлях file.txt.rle
decode;file.txt.rle; – вихідний файл буде мати шлях file.txt
encode;file.txt;example.com
decode;example.com;file.txt
```

Тестування RLE:

Програму протестовано на декількох різних файлах: текстових, зображеннях, коротких відео та документах .docs:

- Текстовий файл що містив Гамлета зменшився на менш ніж 900 байтів при початковому розмірі 187 КБайт.
- Текстові файли стереолітографічного (.stl) змісту зменшились на 5-10% через наявність певних ділянок однакових цифер в числах
- Зображення "чорний текст, білий фон" зменшили свій розмір на 15-20%
- Зображення пейзажів збільшили свій розмір на 1-2% через неповторюваність їх змісту

- Файли з короткими відео збільшились на 1-2%, оскільки вже мають якусь певне кодування та повторення байтів в них – рідкість

Висновки:

- RLE ефективний для файлів з великою кількістю повторюваних байтів;
- RLE не ефективний для файлів які вже стиснуті дуже добре, та/або не мають однакових байтів підряд.

Посилання на код на GitHub:

https://github.com/MINIAProgramStudio/algorithms_of_data_transformation/tree/main/task1